

Fungsi Machine Learning

- Tugas dan Fungsi Machine Learning :

- Klasifikasi
- Regresi
- Prediksi
- Clustering
- *Anomaly detection*
- *Recommendation*
- Feature Extraction

Klasifikasi

- Klasifikasi adalah proses pengelompokan data berdasarkan label atau target tertentu
- Algoritma klasifikasi adalah [machine learning](#) yang berfokus pada kategorisasi yang menyortir data input ke dalam kelas atau kategori berbeda. Model [kecerdasan buatan \(AI\)](#) menggunakan algoritma klasifikasi untuk memproses kumpulan data input terhadap pengklasifikasi tertentu yang menetapkan kriteria bagaimana data harus disortir [1].

Jenis-jenis klasifikasi

- **Klasifikasi biner** : menyortir data ke dalam dua kategori f.
- **Klasifikasi multikelas** : menyortir data ke dalam lebih dari dua kategori.
- **Klasifikasi multilabel** : menyortir data ke dalam kategori noneksklusif.
- **Klasifikasi tidak seimbang** : memiliki distribusi titik data yang tidak merata di seluruh kategori.

Klasifikasi biner

- Dalam masalah klasifikasi biner, model memprediksi apakah data cocok dengan salah satu dari kedua kelas. Teknik pembelajaran yang diterapkan selama pelatihan membuat model menilai fitur dalam data pelatihan dan memprediksi mana dari kemungkinan dua label berlaku pada setiap titik data: positif atau negatif, benar atau salah, dan ya atau tidak.
- Misalnya, filter spam mengklasifikasikan email sebagai *spam* atau *bukan spam*. Selain deteksi spam, model klasifikasi biner membuat prediktor perilaku yang andal: apakah pelanggan berpotensi berhenti atau membeli produk tertentu?

Klasifikasi multikelas

- Masalah klasifikasi multikelas mengklasifikasikan data dengan lebih dari dua label kelas yang semuanya saling terpisah. Dengan cara ini, tantangan multikelas mirip dengan tugas klasifikasi biner, hanya saja memiliki lebih banyak kelas.
- Selain menentukan apakah email adalah spam atau bukan spam, solusi klasifikasi multikelas juga dapat menentukan apakah email adalah promosi atau prioritas tinggi. Misalnya, pengklasifikasi gambar dapat mengklasifikasikan gambar hewan peliharaan dengan menggunakan sangat banyak label kelas, seperti *anjing, kucing, llama, platipus, dan banyak lagi*.
- Tujuan dari metode pembelajaran klasifikasi multikelas adalah untuk mengajarkan model menetapkan input secara akurat ke kemungkinan kategori yang lebih luas.
- Fungsi objektif umum dalam pelatihan multikelas adalah kesalahan lintas entropi kategoris yang menilai kesenjangan antara prediksi model dengan data pengujian dibandingkan dengan label yang benar untuk setiap titik data.

Klasifikasi multilabel

- Klasifikasi multilabel digunakan dalam situasi di mana beberapa label noneksklusif dapat ditetapkan pada setiap titik data.
- Berbeda dengan binary, Multi-label Classification memungkinkan setiap input memiliki lebih dari satu label.
- Tidak seperti tipe klasifikasi berbasis biners, klasifikasi multilabel memungkinkan kemungkinan bahwa titik data menunjukkan karakteristik dari lebih dari satu kategori—cerminan ambiguitas dunia nyata yang lebih dekat dalam kumpulan big data.
- Tugas klasifikasi multilabel sering kali dilakukan dengan menggabungkan prediksi beberapa model klasifikasi biner atau multikelas.
- Contohnya, artikel berita dapat mengandung topik politik, ekonomi, dan teknologi secara bersamaan. Dalam computer vision, satu gambar bisa memuat objek berbeda seperti truk, anjing, pesawat, dan kapal dalam satu waktu.

Klasifikasi tidak seimbang

- Klasifikasi tidak seimbang, di mana beberapa kategori berisi lebih banyak titik data daripada kategori lainnya, memerlukan pendekatan khusus. Ketika kelompok tertentu mengumpulkan lebih banyak titik data, beberapa model klasifikasi menjadi bias terhadap kelompok tersebut dan semakin membuat prediksi yang menguntungkan kelompok tersebut.
- *Class imbalance*, yaitu kondisi di mana jumlah data dari satu kelas jauh lebih banyak daripada kelas lainnya. Ketidakseimbangan ini umum terjadi di berbagai bidang, mulai dari *scam detection*, diagnosis medis, atau klasifikasi citra secara umum. Ketika distribusi data tidak merata, model cenderung belajar lebih baik pada kelas yang sering muncul (mayoritas) dan mengabaikan kelas yang jarang muncul (minoritas).
-

Klasifikasi tidak seimbang

- Sebagai contoh, dalam dataset dengan 95% data “No Fraud” dan hanya 5% data “Fraud”, model yang selalu menebak “No Fraud” bisa mencapai accuracy 95%. Namun, model seperti ini sama sekali tidak berguna karena gagal mengenali kasus penting. Inilah alasan mengapa metrik umum seperti accuracy sering menyesatkan dalam konteks data tidak seimbang [2].

Terdapat beberapa pendekatan yang dapat dilakukan untuk menangani kasus imbalance, yaitu sebagai berikut:

Pendekatan Berbasis Data

Oversampling

- Menambah data pada kelas minoritas, baik dengan duplikasi atau sintesis sampel baru. Metode populer seperti SMOTE (*Synthetic Minority Over-sampling Technique*) membuat data sintetis dengan interpolasi antar contoh minoritas. Kelemahannya adalah risiko overfitting jika sampel baru terlalu mirip dengan data asli.

Undersampling

- Mengurangi jumlah data dari kelas mayoritas agar distribusinya seimbang. Meskipun cepat dan sederhana, teknik ini dapat menghapus informasi penting dan mengurangi keragaman data.

Targeted Data Augmentation

- Menggunakan augmentasi seperti rotasi, flipping, atau color jittering untuk memperbanyak variasi data minoritas. Pendekatan ini efektif di tugas seperti klasifikasi gambar dan deteksi objek.

Synthetic Data Generation

- Menggunakan model generatif seperti GAN (Generative Adversarial Networks) atau Diffusion Models untuk membuat data baru dari kelas langka. Pendekatan ini semakin populer karena mampu menghasilkan sampel yang realistis.

Pendekatan Berbasis Algoritma

Pendekatan ini berfokus pada penyesuaian cara model belajar agar tidak bias terhadap kelas mayoritas.

Class-Weighted Loss

Menetapkan bobot berbeda untuk setiap kelas di dalam fungsi loss. Kelas minoritas diberi bobot lebih tinggi agar model lebih memperhatikannya. Formula umum Weighted Cross Entropy:

$$L = - \sum_i w_i \cdot y_i \cdot \log(p_i)$$

di mana w_i adalah bobot yang berbanding terbalik dengan frekuensi kelas.

Focal Loss

Diperkenalkan oleh Lin et al[3] Focal Loss memberi penekanan lebih pada sampel yang sulit diklasifikasikan dan mengurangi pengaruh sampel yang mudah. Rumusnya:

$$FL(p_t) = -(1 - p_t)^\gamma \cdot \log(p_t)$$

Label Smoothing dan Cost-Sensitive Learning

Label smoothing mencegah model menjadi terlalu yakin terhadap satu kelas dengan mendistribusikan probabilitas target. Sementara cost-sensitive learning mempertimbangkan biaya kesalahan yang berbeda antar kelas, sehingga model lebih berhati-hati terhadap prediksi minoritas.

Two-Stage Training

Pendekatan dua tahap: pertama, melatih model pada seluruh dataset; kedua, fine-tuning menggunakan subset yang berfokus pada kelas minoritas atau sampel yang sulit. Teknik ini sering digunakan di object detection dan medical imaging.

Pendekatan Berbasis Evaluasi

- Evaluasi model harus mencerminkan performa di semua kelas, bukan hanya mayoritas. Oleh karena itu, beberapa metrik yang lebih representatif digunakan:
- Precision dan Recall: Precision mengukur ketepatan prediksi positif, sedangkan Recall menilai seberapa banyak kasus positif berhasil ditemukan.
- F1-Score: Gabungan harmonis antara Precision dan Recall, cocok untuk data tidak seimbang.
- AUC-ROC: Mengukur keseimbangan antara true positive rate dan false positive rate.
- mAP (mean Average Precision): Umum digunakan di deteksi objek untuk menilai akurasi pada berbagai ambang batas.
- Visualisasi seperti confusion matrix juga sangat berguna untuk melihat pola kesalahan antar kelas secara intuitif.

Regresi

Apa itu regresi ?

Regresi adalah suatu metode analisis statistik yang digunakan agar dapat melihat pengaruh antara dua variabel atau lebih.

Hubungan variabel yang dimaksud bersifat fungsional yang diwujudkan dalam bentuk model matematis.

Pada analisis regresi, variabel dibagi menjadi dua jenis yaitu variabel respons atau biasa disebut variabel bergantung/dependen (y) dan variabel bebas atau dikenal dengan istilah variabel independen (x).

Regresi dalam machine learning terdiri dari metode-metode matematis yang memungkinkan data scientist memprediksi hasil kontinu (y) berdasarkan nilai satu atau lebih variabel prediktor (x).

Contoh: Dalam penelitian "Pengaruh Biaya Iklan (X) terhadap Penjualan (Y)", maka **Penjualan** adalah variabel dependen

Regresi

- Algoritma regresi digunakan ketika tujuan utama model adalah memprediksi nilai numerik yang kontinu. Artinya, daripada mengelompokkan data ke dalam kategori, model akan memperkirakan angka seperti harga rumah, pendapatan tahunan, atau suhu cuaca.

Analisis Regresi digunakan untuk :

- **Menganalisis Hubungan:** Mengidentifikasi apakah terdapat hubungan signifikan antara variabel independen dan dependen.
- **Prediksi:** Memprediksi nilai variabel dependen berdasarkan perubahan pada variabel independen.
- **Identifikasi Pengaruh:** Mengukur seberapa besar pengaruh variabel independen terhadap variabel dependen.

Regresi

- Secara umum, tahap-tahap pembuatan suatu model ML regresi adalah sebagai berikut:

1. Mempersiapkan data set $\mathcal{X}$ dan $\mathbf{y}$.
2. Membagi $\mathcal{X}$ dan $\mathbf{y}$ menjadi data training ($\mathcal{X}_{\text{train}}$ dan $\mathbf{y}_{\text{train}}$) dan data tes ($\mathcal{X}_{\text{tes}}$ dan $\mathbf{y}_{\text{tes}}$).
3. Menentukan model regresi yang akan anda gunakan (misal: Random forest) dan juga parameter-parameter model tersebut.
4. Membuat model regresi $\hat{f}(\mathbf{x})$ dengan menggunakan data training $\mathcal{X}_{\text{train}}$ dan $\mathbf{y}_{\text{train}}$.
5. Menganalisis akurasi dari $\hat{f}(\mathbf{x})$ dengan menggunakan teknik seperti cross-validation atau bootstrap, dan juga dengan melihat prediksi pada data tes ($\mathcal{X}_{\text{tes}}$ dan $\mathbf{y}_{\text{tes}}$).

Jenis-Jenis Analisis Regresi

1. Regresi Linear Sederhana

- Regresi linear adalah bentuk paling dasar dari analisis regresi yang melibatkan satu variabel bebas (X) dan satu variabel terikat (Y). Hubungan antara kedua variabel ini direpresentasikan sebagai garis lurus pada grafik.

- Rumus:

$$Y = \alpha + bX$$

Di mana:

- Y = Variabel dependen
- X = Variabel independen
- α = Konstanta
- b = Koefisien regresi

Contoh kasus:

- Memprediksi penjualan berdasarkan anggaran iklan.
- Memprediksi tinggi badan berdasarkan usia anak.
- Hubungan antara jumlah jam belajar (X) dan nilai ujian siswa (Y).
- Model regresi linear sederhana digunakan ketika hubungan antara variabel tampak linear, artinya jika satu variabel meningkat, variabel lainnya juga meningkat (atau sebaliknya).

Implementasi Regresi dalam Dunia Nyata

[4]

- **Prediksi Harga Rumah:** Model regresi dapat digunakan untuk memprediksi harga rumah berdasarkan luas tanah, jumlah kamar, lokasi, dan faktor lainnya. Informasi ini sangat berguna bagi agen properti, pembeli, dan penjual rumah.
- **Analisis Sentimen Pasar:** Regresi dapat digunakan untuk menganalisis sentimen pasar terhadap suatu saham atau produk dengan menggunakan data teks dari media sosial atau berita.
- **Prediksi Penjualan:** Perusahaan dapat menggunakan regresi untuk memprediksi penjualan produk mereka berdasarkan faktor-faktor seperti harga, promosi, dan kondisi ekonomi.
- **Optimasi Kampanye Pemasaran:** Regresi dapat digunakan untuk mengoptimalkan alokasi anggaran pemasaran dengan memprediksi efektivitas berbagai saluran pemasaran.

Jenis-Jenis Analisis Regresi

2. Regresi Linear Berganda

- Regresi linear berganda digunakan jika terdapat lebih dari satu variabel independen yang memengaruhi variabel dependen.
- Metode ini digunakan untuk melihat hubungan antara dua atau lebih variabel independen dengan satu variabel dependen.

• Rumus:

$$Y = \alpha + b_1 X_1 + b_2 X_2 + \dots + b_n X_n$$

Di mana:

- Y = Variabel dependen
- $X_1, X_2, \dots, X_n$ = Variabel independen
- $b_1, b_2, \dots, b_n$ = Koefisien regresi masing-masing variabel independen

- Misalnya, penjualan produk mungkin tidak hanya dipengaruhi oleh anggaran iklan, tetapi juga oleh harga produk, diskon, dan kualitas layanan pelanggan.
- Contoh kasus:
- Memprediksi harga rumah (y) berdasarkan luas bangunan (x_1), lokasi (x_2), dan jumlah kamar (x_3).
- Menganalisis faktor-faktor yang memengaruhi kepuasan pelanggan.
- Hubungan antara tingkat pendidikan X_1 , pengalaman kerja X_2 , dan gaji bulanan Y .

Jenis-Jenis Analisis Regresi

3. Regresi Non-Linear [5]

- Tidak semua hubungan antarvariabel bersifat linear. Jika hubungan tersebut membentuk kurva atau pola non-linier, maka digunakan regresi non-linear. Model ini lebih kompleks, tetapi lebih akurat dalam situasi di mana hubungan tidak membentuk garis lurus.
- Metode ini menggunakan persamaan matematika seperti polinomial, eksponensial, atau logistik, serta teknik iteratif (algoritma) untuk memprediksi hasil dengan akurasi yang lebih tinggi.

Contoh kasus:

- Pertumbuhan populasi terhadap waktu.
- Reaksi kimia yang tidak proporsional terhadap perubahan suhu.

Jenis-Jenis Analisis Regresi

4. Regresi Logistik [5]

Berbeda dengan regresi linear, regresi logistik digunakan ketika variabel dependen bersifat kategorikal (misalnya “ya” atau “tidak”). Model ini sangat penting dalam klasifikasi dan prediksi probabilitas.

Contoh kasus:

- Memprediksi apakah pelanggan akan membeli produk (ya/tidak).
- Memprediksi kemungkinan pasien menderita suatu penyakit.

Fungsi utama analisis regresi:

- Menentukan hubungan antara variabel bebas dan terikat.
- Membuat prediksi berdasarkan data historis.
- Mengidentifikasi variabel yang memiliki pengaruh paling signifikan.
- Menilai kekuatan dan arah pengaruh variabel bebas terhadap variabel terikat.

Regresi Logistik: Digunakan untuk memprediksi variabel dependen yang bersifat kategorik (misalnya, ya atau tidak).

Prediksi

- *Prediksi* adalah proses menggunakan model yang telah dilatih dengan data untuk memperkirakan nilai atau label pada data baru yang belum pernah dilihat sebelumnya.
- Data masa lalu → Latih model → Model memprediksi data masa depan/baru
- Prediksi menggunakan algoritma untuk menganalisis data historis dan mengenali pola, guna meramalkan kejadian atau nilai di masa depan secara otomatis.
- Teknik ini, seperti regresi dan klasifikasi, digunakan dalam berbagai industri untuk memprediksi tren pasar, permintaan stok, cuaca, hingga risiko penyakit.

Jenis – jenis Prediksi:

Regresi: Memprediksi nilai numerik (contoh: harga saham, angka penjualan).

Ciri-ciri:

- Output berupa angka
- Biasanya nilai yang bisa memiliki pecahan/desimal

Contoh:

- Prediksi harga rumah
- Prediksi suhu besok
- Estimasi penjualan bulan depan
- Prediksi skor ujian siswa

Klasifikasi: Memprediksi kategori atau label (contoh: ya/tidak, spam/bukan).

Ciri-ciri:

- Output berupa label/kategori
- Biasanya diskrit (ya/tidak, spam/tidak spam, sakit/sehat)

Contoh:

- Email termasuk **spam atau tidak spam**
- Diagnosis penyakit: **positif atau negatif**
- Deteksi wajah dalam foto
- Prediksi apakah pelanggan akan berhenti berlangganan (churn)

Jenis – jenis Prediksi:

Prediksi Deret Waktu (Time Series Forecasting)

- Digunakan untuk memprediksi nilai berdasarkan **pola waktu historis**.

Ciri-ciri:

- Data memiliki urutan waktu
- Memperhatikan tren dan musiman

Contoh:

- Prediksi harga saham
- Prediksi permintaan produk mingguan
- Prediksi jumlah penumpang harian
- Peramalan inflasi

Prediksi Clustering (Unsupervised Prediction)

Digunakan untuk **mengelompokkan data tanpa label**.

Ciri-ciri:

- Tidak ada label target
- Mencari pola tersembunyi dalam data

Contoh:

- Segmentasi pelanggan
- Pengelompokan produk berdasarkan perilaku pembelian
- Analisis pola kebiasaan pengguna

Prediksi dalam machine learning dapat dibagi menjadi:

- **Klasifikasi** → menebak kategori
- **Regresi** → menebak angka
- **Time series** → menebak nilai berdasarkan waktu
- **Clustering** → mengelompokkan data

Clustering

Clustering merupakan suatu teknik dalam Data Mining dan Machine Learning yang melibatkan pengelompokan sejumlah objek agar objek-objek dalam kelompok yang sama (disebut Cluster) memiliki karakteristik yang serupa dibandingkan dengan objek di luar kelompok [6]

Menurut Tan[7] *clustering* adalah sebuah proses untuk mengelompokkan data ke dalam beberapa *cluster* atau kelompok sehingga data dalam satu *cluster* memiliki tingkat kemiripan yang maksimum dan data antar *cluster* memiliki kemiripan yang minimum.

Konsep pengelompokan dalam Machine Learning secara sederhana merujuk pada proses mesin belajar yang mengkategorikan data tanpa label kelas (data tidak berlabel).

Clustering

- *Clustering* merupakan proses partisi satu *set* objek data ke dalam himpunan bagian yang disebut dengan *cluster*.
- Objek yang di dalam *cluster* memiliki kemiripan karakteristik antar satu sama lainnya dan berbeda dengan *cluster* yang lain.
- Partisi tidak dilakukan secara manual melainkan dengan suatu algoritma *clustering*. Oleh karena itu, *clustering* sangat berguna dan bisa menemukan *group* atau kelompok yang tidak dikenal dalam data.
- *Clustering* banyak digunakan dalam berbagai aplikasi seperti misalnya pada *business intelligence*, pengenalan pola citra, *web search*, bidang ilmu biologi, dan untuk keamanan (*security*).
- Di dalam *business intelligence*, *clustering* bisa mengatur banyak *customer* ke dalam banyaknya kelompok.
- Contohnya mengelompokkan *customer* ke dalam beberapa *cluster* dengan kesamaan karakteristik yang kuat. *Clustering* juga dikenal sebagai data segmentasi karena *clustering* mempartisi banyak data set ke dalam banyak *group* berdasarkan kesamaannya.
- Selain itu *clustering* juga bisa sebagai *outlier detection*.

Kapan Clustering digunakan ?[8]

a. Saat analisis dimulai dengan dataset yang besar dan tidak terstruktur

Kondisi ini merupakan kondisi yang paling tepat untuk menggunakan algoritma *clustering* dikarenakan algoritma *clustering* dapat mengambil *dataset* dengan jumlah yang banyak, tanpa adanya instruksi lalu mengubahnya menjadi sesuatu yang berguna.

b. Saat tidak diketahui jumlah dari kelas yang ingin dibagi

Clustering adalah salah satu langkah yang tepat apabila kamu ingin memulai tahap data preparasi dikarenakan dengan algoritma *clustering*, *business question* yang ditetapkan dapat terjawab terkait dengan dataset.

c. Saat ingin mencari anomali pada *dataset*

Apabila ingin mencari anomali pada dataset, maka menggunakan algoritma *clustering* adalah pilihan yang tepat karena dengan algoritma ini, anomali pada data dapat diidentifikasi sehingga dapat membantu untuk mengoptimalkan hasil yang didapat untuk jangka panjang


Jenis-jenis Clustering

Partitional clustering/ Centroid-based clustering

Partitional clustering yaitu data dikelompokkan ke dalam sejumlah *cluster* tanpa adanya struktur hirarki antara satu dengan yang lainnya.


Pada metode *partitional clustering* setiap *cluster* memiliki titik pusat *cluster* (centroid) dan secara umum metode ini memiliki fungsi tujuan yaitu meminimumkan jarak (*dissimilarity*) dari seluruh data ke pusat *cluster* masing-masing.

Contoh metode *partitional clustering*: K-Means, Fuzzy K-means dan *Mixture Modelling*.



Gambar 1.2 Proses Clustering Obyek Menggunakan metode k-Means

(Sumber: Han dkk, 2012)



Jenis-jenis Clustering

Hierarchical clustering

Hierarchical clustering adalah metode yang menciptakan hierarki *cluster*. Metode ini bisa berupa *agglomerative (bottom-up)* atau *divisive (top-down)*.

Agglomerative bekerja menjadikan setiap titik data sebagai *cluster* individu dan menggabungkannya berdasarkan kesamaan.

Sementara *divisive* membuat semua titik data dalam satu *cluster* dan membaginya sampai setiap *cluster* hanya berisi satu titik data.



Density-based Clustering

Density-based clustering menghubungkan area dengan kepadatan yang sama ke dalam satu kelompok, tipe ini memiliki kesulitan dengan data beragam kepadatan dengan dimensi yang tinggi. Dalam metode ini, *cluster* akan dibuat berdasarkan kepadatan dari masing masing *data point*.

Nantinya wilayah yang menjadi padat karena banyaknya *data point* yang berada di wilayah akan dianggap sebagai satu kelompok/*cluster*. Sebaliknya, wilayah yang memiliki *data point* sangat sedikit akan dianggap sebagai *noise* atau *outlier*.





Photo by researchgate.net

Distribution-based Clustering

Jenis algoritma pengelompokan (*clustering*) yang mengasumsikan data terbentuk dari kombinasi beberapa distribusi probabilitas (seperti *Gaussian/Normal Distribution*), di mana kluster ditentukan berdasarkan probabilitas titik data termasuk ke dalam distribusi tertentu. Semakin jauh titik data dari pusat distribusi, semakin kecil probabilitasnya untuk masuk ke kelompok tersebut.



Anomaly detection

- Anomali dapat didefinisikan sebagai suatu entitas yang memiliki ciri khas unik dan sangat berbeda.
- Dalam konteks data Anomali dapat dipahami sebagai suatu observasi yang memiliki nilai sangat berbeda dibandingkan dengan pengamatan lain.
- Dalam bidang statistika anomali lebih sering dikenal dengan istilah **outliers**.
- Tujuan utama dari anomaly detection adalah membuat sebuah model yang dapat mendeteksi dan menjelaskan suatu anomali dalam sebuah dataset.
- Aplikasi dari anomaly detection sering kali dapat kita temukan dalam kehidupan sehari-hari kita, salah satunya mendeteksi transaksi mencurigakan menggunakan kartu kredit.
- Tidak hanya itu anomaly detection dapat diaplikasikan pada bidang-bidang yang tidak umum seperti mendeteksi kegagalan / lifetime dari suatu mesin pada industri manufaktur.

Jenis-jenis *Anomaly detection*

Supervised Anomaly Detection

- Dataset memiliki label (normal vs anomali) dan biasanya menggunakan algoritma klasifikasi

Kelebihan:

Akurat jika data berlabel cukup dan representatif.

Kekurangan:

Sulit mendapatkan data anomali yang lengkap (karena kasus aneh jarang terjadi).

Contoh kasus:

Deteksi fraud kartu kredit dengan data transaksi yang sudah diberi label.

Unsupervised Anomaly Detection

- Tidak membutuhkan label dan mengasumsikan bahwa anomali jarang dan berbeda secara statistik.
- Ini adalah pendekatan yang paling umum digunakan

Contoh kasus:

- Deteksi serangan jaringan (intrusion detection).
- Monitoring sensor industri.

Semi-Supervised Anomaly Detection

- Dilatih hanya dengan data normal dan model belajar pola normal lalu mendeteksi penyimpangan

Cocok untuk:

- Situasi di mana data anomali sangat jarang atau sulit dikumpulkan.


Jenis-jenis *Anomaly detection*

Time-Series Anomaly Detection

- Digunakan untuk data berbasis waktu (time series).
- Deteksi anomali deret waktu mengidentifikasi pola tak terduga, seperti lonjakan, penurunan, atau pergeseran struktural (structural shifts/break) , dalam data yang diurutkan berdasarkan waktu (misalnya, data sensor, keuangan).
- Patah struktural (structural shifts/break)mengacu pada perubahan mendadak dan signifikan dalam hubungan mendasar antara variabel dalam deret waktu.
- Perubahan-perubahan ini mengganggu konsistensi proses penghasil data, membuat model yang dikalibrasi pada data sebelum perubahan tidak cocok untuk analisis setelah perubahan.
- Perubahan semacam itu umum terjadi dalam sistem ekonomi dan keuangan akibat peristiwa seperti pergeseran kebijakan, krisis ekonomi, atau gangguan **teknologi**.

Contoh

- Monitoring server (lonjakan CPU abnormal).
- Deteksi anomali harga saham



Jenis-jenis *Anomaly detection*

Statistical-Based Anomaly Detection

- Berbasis distribusi statistik.
- Cocok untuk dataset kecil dan distribusi sederhana.
-  Data normal mengikuti distribusi tertentu
-  Data yang probabilitasnya sangat kecil dianggap anomali

Kelebihan

- Sederhana dan cepat
- Mudah diimplementasikan
- Cocok untuk dataset kecil

Kekurangan

- Sensitif terhadap asumsi distribusi
- Kurang efektif untuk data kompleks/high-dimensional
- Tidak selalu cocok untuk time-series non-stationary


Jenis anomali lainnya

Point Anomalies/Anomali Titik:

- Anomali titik terjadi ketika satu titik data individu menyimpang secara signifikan dari data lainnya. Ini adalah bentuk anomali yang paling sederhana dan mudah diidentifikasi dalam sebuah dataset di mana satu titik atau beberapa titik sangat berbeda dari pengamatan lainnya.

Contoh :

- seperti ketika seseorang yang biasanya menghabiskan \$100 untuk belanja bulanan tiba-tiba menghabiskan \$10.000.
- Jenis anomali ini dapat menandakan penipuan atau kesalahan sistem yang memerlukan perhatian segera.



Jenis anomali lainnya

Collective Anomalies


- Anomali kolektif adalah pola di mana sekelompok titik data menjadi anomali bersama-sama, meskipun setiap titik terlihat normal secara terpisah. Jenis anomali ini muncul dari urutan atau kumpulan nilai yang menyimpang secara keseluruhan dari perilaku yang diharapkan.
- Seringkali ini menunjukkan masalah yang berkelanjutan atau pergeseran sistemik yang mempengaruhi beberapa titik data secara berurutan—sesuatu yang akan Anda lewatkan jika hanya memeriksa titik-titik individu.

Contoh :

Satu login gagal → normal

Dua login gagal → masih normal

• 100 login gagal dalam 1 menit →  anomali kolektif



Jenis anomali lainnya

Contextual anomaly

- Anomali kontekstual adalah titik data yang tidak biasa dalam konteks tertentu (seperti waktu dalam sehari, hari dalam seminggu, atau musim) meskipun mungkin normal dalam arti yang lebih luas.
- **Contextual anomaly** adalah data yang tampak normal secara umum, tetapi menjadi aneh jika dilihat dalam konteks tertentu (misalnya waktu, lokasi, musim, atau kondisi tertentu).
- Konteks memberikan ekspektasi dasar, jadi sebuah titik menjadi anomal hanya ketika dibandingkan dengan yang lain dalam konteksnya (misalnya nilai saham Senin ini dibandingkan dengan Senin yang biasa).


Contoh :


Penggunaan Listrik Rumah ⚡

- Konsumsi tinggi pukul 19.00 → normal (jam sibuk)
- Konsumsi tinggi pukul 03.00 → mencurigakan
- Nilainya sama, konteks waktunya berbeda.


Transaksi Kartu Kredit 🏠

- Transaksi Rp5 juta di kota tempat tinggal → normal
- Transaksi Rp5 juta di negara lain dalam waktu bersamaan → 🚨 anomali
- Nilainya tidak besar, tapi konteks lokasi dan waktu membuatnya mencurigakan.








Types of anomalies: "a) point anomaly; b) contextual anomaly; and c) collective anomaly"



Examples of point anomalies (a), collective anomalies (b), and combination of both (c) (color figure online)



Recommendation

- Cabang AI dan machine learning yang memprediksi preferensi pengguna (film, produk, lagu) berdasarkan data historis, perilaku klik, dan profil pengguna.
- Tujuannya adalah mempersonalisasi pengalaman, meningkatkan keterlibatan, dan membantu pengguna menemukan item relevan secara otomatis

Contoh :

- Streaming (Netflix/Spotify): Rekomendasi film/musik sesuai selera.
- E-commerce (Amazon/Shopee): Saran produk "Mungkin Anda Suka"
- Media Sosial: Rekomendasi konten/teman

Jenis –jenis Sistem Rekomendasi:

- **Collaborative Filtering**: Memberikan rekomendasi berdasarkan perilaku pengguna lain yang mirip atau pola interaksi masa lalu (contoh: "User yang membeli ini juga membeli...").
- **Content-Based Filtering**: Merekomendasikan item yang serupa dengan apa yang disukai pengguna sebelumnya, berdasarkan fitur item tersebut (contoh: genre film, kategori produk).
- **Hybrid Model**: Menggabungkan keduanya untuk akurasi yang lebih tinggi

Feature Extraction

Feature extraction adalah proses mengubah data mentah (teks, gambar, suara, sinyal, dll.) menjadi **fitur numerik yang relevan** sehingga bisa diproses oleh algoritma machine learning.

Tujuan utamanya:

- Mengurangi dimensi data
- Menghilangkan noise
- Menonjolkan informasi penting
- Meningkatkan performa model

Jenis-Jenis Feature Extraction

Feature Extraction untuk Data Tabular

- Digunakan pada dataset numerik/kategorikal.

Feature Extraction untuk Teks (NLP)

- Mengubah teks menjadi representasi numerik.

Feature Extraction untuk Gambar (Computer Vision)

- Digunakan untuk klasifikasi gambar, deteksi objek, dll.

Feature Extraction untuk Audio & Sinyal

- Digunakan pada speech recognition, IoT, biomedical signal.

Feature Extraction untuk Time-Series

- Digunakan pada data berbasis waktu.

Tugas

- Dari berbagai fungsi beserta jenis-jenis dari pembelajaran mesin yang telah dijelaskan, berikan contoh algoritma dari jenis-jenis fungsi pembelajaran mesin.

Contoh :

- Klasifikasi biner : Support Vector Machine, Decision Tree
- <https://classroom.google.com/c/ODQ3Njk4NjUwMDU5/a/ODQ3Njk5NDkyMjYz/details>

Referensi

- [1] I. Belcic, "Klasifikasi dalam Machine Learning," *Ibm.com*, Oct. 15, 2024.
<https://www.ibm.com/id-id/think/topics/classification-machine-learning>
- [2] Class Imbalance dalam Deep Learning: Strategi dan Solusinya," *Binus.ac.id*, 2024.
<https://socs.binus.ac.id/2025/11/04/class-imbalance-dalam-deep-learning-strategi-dan-solusinya/>.
- [3] Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. In Proceedings of the IEEE international conference on computer vision (pp. 2980-2988).
- [4] Ariska Anggraini, "Implementasi Regresi dalam Machine Learning: Panduan Lengkap - London School of Accountancy And Finance | Blog," *London School of Accountancy And Finance | Blog*, Oct. 08, 2024.
<https://lsafglobal.com/blog/1515/regresi-dalam-machine-learning/>.
- [5] Dwi, "Regresi: Pengertian, Rumus, dan Contoh Analisis," *Teknik Biomedis Universitas Telkom*, Oct. 15, 2025.
<https://bbe.telkomuniversity.ac.id/regresi-pengertian-rumus-dan-contoh-analisis/>
- [6] Clustering dalam Data Science : Pengertian, Jenis dan Cara Kerjanya," *Cakrawala.ac.id*, 2024.
<https://www.cakrawala.ac.id/berita/clustering-data-adalah>
- [7] CLUSTERING," *School of Computer Science*. <https://socs.binus.ac.id/2017/03/09/clustering/>
- [8] *Codingstudio.id*, 2026. <https://codingstudio.id/blog/mengenal-clustering/> (accessed Mar. 03, 2026).
- [9] Han, J., Kamber, M., Pei, J.: Data Mining Concept and Techniques, 3rd ed. Morgan Kaufmann-Elsevier, Amsterdam (2012)